

ChabotAI 伙伴

AI 人格聊天应用软件

软件设计说明书

V1.4.3

软件全称	ChabotAI 伙伴
软件简称	AI 伙伴
软件版本	V1.4.3
著作权人	陈聪
文档类型	软件设计说明书
编制日期	2026 年 9 月

【版权声明】 本软件设计说明书为“ChabotAI 伙伴 V1.4.3”的配套文档，仅供计算机软件著作权登记审查使用。软件的著作权人为陈聪，受《中华人民共和国著作权法》及相关法律法规保护。未经著作权人书面许可，任何单位和个人不得以任何方式复制、传播、销售或用于其他商业用途。本说明书所描述的功能、结构、接口与数据设计均以实际交付的源程序为准。

【文档说明】 本文档依据软件源代码与功能实现编写，全面介绍软件的概述、运行环境、系统架构、模块功能设计、数据结构设计、接口设计、技术特点、测试结果与使用方法，供登记审查与后续维护参考。

目录

1	概述	2
1.1	软件简介	2
1.2	开发目的	2
1.3	面向领域与行业	3
2	运行环境	3
2.1	硬件环境	3
2.2	软件环境	3
3	系统架构	3
3.1	总体架构	3
3.2	模块划分	3
4	模块功能设计	4
4.1	智能聊天模块	4
4.2	记忆系统模块	4
4.3	会话管理模块	4
4.4	上下文压缩模块	4
4.5	情景感知模块	5
4.6	表情包系统模块	5
4.7	语音阅读模块	5
4.8	拟真聊天模块	5
4.9	设置与数据管理模块	5
5	数据结构设计	6
5.1	持久化存储设计	6
5.2	主要数据结构	6
6	接口设计	6
6.1	外部接口	6
6.2	内部接口	6
7	技术特点	6
7.1	跨端一次编写、多端运行	6
7.2	纯端侧、零后端	7
7.3	三级记忆与多样化检索	7
7.4	情景感知与上下文压缩	7
7.5	拟真主动聊天	7
7.6	丰富的辅助能力	7
8	测试结果	7
8.1	测试环境	7
8.2	测试内容与结论	7
9	使用说明	7
9.1	安装与导入	7
9.2	功能使用	8

10 界面与交互说明	8
10.1 聊天主界面	8
10.2 记忆管理界面	8
10.3 表情管理界面	8
10.4 设置界面	8
10.5 交互反馈	8
11 异常处理与容错	9
11.1 接口容错	9
11.2 存储容错	9
11.3 调度容错	9
11.4 数据安全	9
12 版本记录	9
13 附录：主要程序文件说明	9
13.1 聊天服务层	9
13.2 存储层	9
13.3 记忆与提示词	10
13.4 辅助能力	10
13.5 页面层	10
13.6 测试脚本	10
13.7 工程配置与入口文件	10
14 结语	10

1 概述

1.1 软件简介

ChabotAI 伙伴是一款基于大语言模型的跨端 AI 人格聊天应用软件，无后端、纯端侧运行。软件采用 uni-app（Vue 3）技术栈开发，一套源代码即可编译运行于 Android、iOS（App）、H5 浏览器以及微信小程序等平台。软件调用任意 OpenAI 兼容的 /chat/completions 接口完成智能对话，通过系统提示词定义 AI 伙伴的个性化人格，并围绕记忆、情景、上下文压缩、表情包、语音阅读、拟真聊天等能力，为用户提供可持续、可定制的虚拟陪伴体验。

软件整体采用组件化与模块化设计：聊天页由若干子组件构成；底层逻辑按职责划分为聊天服务（chat）、存储（storage）、记忆（memory）、提示词（prompts）、表情（emojis）、语音（tts）、调试日志（log）、通知（notify）、导出（export）等多个功能模块。模块之间通过统一门面与共享状态协同，职责清晰、易于扩展与维护。

1.2 开发目的

软件旨在为用户提供一款无需后端服务器、可自由接入任意大模型接口的 AI 人格聊天工具。用户可自定义伙伴的人格、知识记忆与互动频率，使其逐渐成长为贴合用户习惯的个性化 AI 伙伴。软件同时强调端侧数据隐私：聊天记录、记忆与设置均保存在用户本地设备，不上传任何云端。

1.3 面向领域与行业

软件面向人工智能与移动应用领域，适用于大模型对话、虚拟陪伴、数字人聊天、角色扮演等场景，可供普通用户作为个人聊天工具使用，也可作为大模型端侧应用的参考实现。

2 运行环境

2.1 硬件环境

开发硬件环境：PC 兼容机一台，CPU 为 Intel Core i5 及以上，内存 16GB，固态硬盘 512GB，配 Android 真机或模拟器用于调试验证。

运行硬件环境：Android 5.0 及以上 / iOS 9 及以上智能手机（内存 4GB 及以上），或安装现代浏览器的 Windows / macOS 电脑。

2.2 软件环境

开发软件环境：操作系统为 Windows 10 64 位；开发工具为 HBuilderX、Visual Studio Code；开发框架为 uni-app（Vue 3）；辅助工具链为 Node.js（用于运行自动化测试脚本）。

运行软件环境：Android/iOS 原生运行环境、HTML5 浏览器内核、微信小程序运行环境。软件本身无第三方运行时依赖，运行支撑软件主要为远程 OpenAI 兼容的大模型接口服务与 Qwen-TTS 语音合成接口服务。

3 系统架构

3.1 总体架构

软件整体为单一应用工程，由四个层次构成：

1. **页面视图层：**负责各页面与用户交互，包括聊天页、记忆管理页、表情管理页、设置页及若干设置子页；
2. **聊天服务层：**封装发送、校验、记忆、情景、压缩、拟真等核心业务流程；
3. **存储门面层：**统一封装跨端持久化读写；
4. **外部接口层：**通过统一网络请求组件调用远程 LLM 接口与 TTS 语音合成接口。

聊天页作为主界面持有会话状态，七个聊天子组件（头部、消息列表、输入栏、表情栏、情景编辑、历史、人格）通过属性下发与事件上报机制与页面协调。

3.2 模块划分

程序主要模块划分如下：

- **聊天服务域：**chat（门面与发送主链路）、chat-state（共享状态）、chat-settings（设置域）、chat-conversations（会话域）、chat-compress（压缩域）、chat-proactive（拟真聊天域）；
- **存储域：**storage（持久化门面）、storage-state（底层与共享状态）、storage-conversations（会话）、storage-scene（情景）、storage-api（API 预设）、storage-background（聊天背景）；
- **记忆域：**memory（记忆核心）、memory-similarity（相似度）、memory-parse（Memory 行解析）、memory-constants（常量）；
- **提示词域：**prompts（系统提示词构建、人格预设、接口预设）；

- **辅助能力域**: emojis (表情数据层)、llm (LLM 客户端)、tts (语音阅读)、log (调试日志)、notify (系统通知)、export (记录导出);
- **页面层**: pages/chat 下聊天页与子组件、pages/memory 记忆页、pages/emoji 表情页、pages/settings 下设置页与设置子页。

4 模块功能设计

4.1 智能聊天模块

聊天模块负责对话主链路。发送消息时依次完成: 检索记忆、组装系统提示词 (人格、规则、记忆指南、情景指南、当前状态、记忆上下文、记忆容量状态、表情清单)、注入未压缩历史、调用 LLM、格式校验、情景与记忆更新、回复落库、执行维护与上下文压缩。

回复格式校验为聊天模块的关键设计: 要求回复内含对话文本, Scene 行有内容, Memory 行可解析, 并校验表情占位均在表情清单内; 不合格自动重新请求, 最多重试设置项指定的次数, 从而保证落库数据规范。

若当前会话开启拟真聊天且时间模式为现实时间, 则所有回复还需满足每条不超过一句、连续表情不超过两个的约束, 并按换行拆分为多条气泡落库。

4.2 记忆系统模块

记忆系统采用三级记忆模型: L1 核心事实永不衰减 (重点事实永久保留); L2 情景记忆慢衰减, 用作与用户的约定与待办清单; L3 临时信息快衰减, 用于近期琐事与临时状态。

记忆由大模型驱动写入: 系统提示词内置记忆书写指南, 大模型在回复末尾输出结构化的 Memory 行, 程序解析并执行新增、修改或删除操作; 修改与删除按内容逐字匹配, 找不到匹配则静默忽略。

记忆具备如下核心机制:

- **去重合并**: 字符 bigram Jaccard 相似度与 LCS 序列相似度加权判定, 超过阈值视为近似记忆并合并;
- **召回冷却**: 记忆被召回后一段时间内禁止重复保存, 复读视为强调并提升重要性 (上限 5 级);
- **分层检索**: 全量召回 L1 核心事实、新鲜槽与 MMR 多样性槽混合检索, 总配额 30 条、多样性系数 0.7;
- **周期维护**: L3 过期清理、L2/L3 升降级、容量淘汰 (上限 200 条);
- **时间模式**: 支持现实时间与虚拟时间两种衰减模式, 虚拟模式下按剧情时刻相对衰减, 现实中断不衰减。

4.3 会话管理模块

软件支持多会话管理: 可新建、切换、删除、复制会话; 开始新对话时会复制当前会话的完整设置快照; 每个会话独立保存人格与设置; 会话标题自动取首条用户消息; 提供历史弹窗进行切换、删除、压缩上文与导出对话记录; 支持复制会话或仅复制记忆到新会话。

4.4 上下文压缩模块

为控制请求长度、节省 token 并保持上下文连贯, 软件支持将历史对话压缩为概要。可手动触发, 也可按设置条数在每轮回复落库后自动触发; 压缩范围按上次进度计算, 保留最近指定条数的消息; 超

过批处理上限时分批调用、逐批合并概要，避免单次请求过大；概要写入会话并注入后续请求，原始消息仍完整保留可翻阅。

4.5 情景感知模块

软件提供当前情景识别能力。大模型每次回复输出 Scene 行描述用户当前所处的场景，程序结合注入的时间判断用户此刻在做什么，并持久化到情景历史（最多 10 条，先进先出）。支持实时时间与虚拟时间两种模式：实时时间模式注入真实当前时间供情景判断；虚拟时间模式不发送真实时间，由大模型自由想象情景氛围。聊天页顶部以情景条展示，可点击查看、修改或清除。

4.6 表情包系统模块

软件内置自定义表情包系统：支持批量上传图片并逐张命名，命名全局唯一、限长；支持改名、删除与拖拽排序；表情图片按平台持久化（App 与小程序压缩后存文件，H5 压缩为 base64）。

对话中以 \$ 表情名 \$ 占位引用表情并渲染为图片；程序提供消息拆分解析（跳过空白段、裁剪首尾空白），清单外的未知占位原样保留；可通过设置开关控制是否将表情清单注入系统提示词，以决定大模型是否主动使用表情。

4.7 语音阅读模块

软件对接 Qwen-TTS 非流式语音合成接口，可将 AI 回复朗读出来。支持音色选择（内置常用音色清单并支持手动输入）、模型与接口地址配置、接口测试。

语音阅读具备多项细节设计：表情不朗读（仅朗读文本段）；文本截断到接口上限；拿到音频直链后直接播放、不落盘；同一时刻只播一条；App 端等待可播放事件后再播放并设兜底重试；首次播放失败会自动重新合成一次。

4.8 拟真聊天模块

拟真聊天用于模拟真人发消息：AI 会在设定的时间窗口内按频率档位随机主动给用户发消息，每条不超过一句、连续表情不超过两个。

调度采用单条链式定时器，空闲零唤醒；退后台不清除定时器，App 真后台脚本挂起时由回前台补发；到期触发时刻持久化到存储，进程重启后对齐恢复；触发具备门禁（开关、现实时间、未抑制、时段窗口、已有用户消息），每次被拦截都会记录原因日志。可选开启系统后台通知（App 本地通知 / H5 浏览器通知），仅在应用处于后台时弹出。

4.9 设置与数据管理模块

设置页集中管理：接口配置（接口地址、API Key、模型、温度，支持最多 3 套预设快速切换）、思考模式、请求次数上限、人格配置、聊天表情包开关、语音阅读配置、聊天背景图、上下文压缩间隔、数据管理（清空、迁移、恢复）与调试日志面板。

软件内置调试日志系统：采用环形缓冲区，记录请求、响应、错误与信息四类日志，可在调试面板按类型过滤、展开查看详情、刷新与清空，便于问题排查。

5 数据结构设计

5.1 持久化存储设计

软件采用同步键值存储实现多端持久化（App、H5、小程序通用）。聊天会话以数组形式存储，每个会话包含编号、标题、创建与更新时间、概要、压缩进度、设置快照、情景历史、记忆与消息列表；另有当前会话编号用于记录活动会话。

设置项统一以前缀 `chabot_setting_` 存储；记忆、情景历史、表情列表、API 预设、背景图等按各自键名独立存储。首次启动会把旧版聊天历史自动迁移为第一个会话。

5.2 主要数据结构

- **会话对象**：包含 `id`、`title`、`created_at`、`updated_at`、`summary`、`compressedUntil`、`settings`、`scenes`、`memories`、`messages` 字段；
- **消息对象**：包含 `id`、`role`、`content`、`time` 字段；
- **记忆对象**：包含 `id`、`category`、`content`、`importance`、`level`、`created_at`、`last_accessed_at`、`access_count` 字段；
- **表情对象**：包含 `id`、`name`、`src`、`created_at` 字段；
- **情景对象**：包含 `text`、`time` 字段。

各对象字段随模块实现相应扩展。

6 接口设计

6.1 外部接口

LLM 对话接口：调用 OpenAI 兼容接口 `/chat/completions`，请求体包含 `model`、`messages` 与 `temperature`、`stream` 等参数，强制非流式并解析响应 `content` 字段；通过 `reasoning_effort` 控制思考型模型的思考模式；服务端不识别参数时自动移除参数降级重试。

语音合成接口：对接 Qwen-TTS 非流式语音合成接口，请求含模型名、音色与文本，响应解析音频直链用于播放。

6.2 内部接口

软件将各域对外开放的公共接口通过存储门面与聊天门面统一导出，页面层仅依赖门面接口即可完成全部业务，降低耦合。例如记忆增删改查、会话管理、设置读写、表情管理与解析、日志记录等均通过门面暴露，调用方无需感知底层存储实现。

7 技术特点

7.1 跨端一次编写、多端运行

基于 uni-app（Vue 3）与条件编译，一套源代码即可打包为 App（Android/iOS）、H5 与微信小程序，显著降低多平台开发与维护成本；针对各平台差异（数据持久化、图片压缩、语音播放等）以条件编译与运行时能力检测适配。

7.2 纯端侧、零后端

聊天、记忆与设置全部在端上完成，不需要专属服务器；仅按需对接用户自配的大模型与语音接口，最大限度保护用户数据隐私。

7.3 三级记忆与多样化检索

采用 L1/L2/L3 三级半衰期记忆模型、重要性与召回强化因子、MMR 多样性与新鲜槽混合检索，实现个性化、可持续的记忆与对话。

7.4 情景感知与上下文压缩

借助 Scene 行感知用户当前情景，支持实时与虚拟时间模式；将历史对话压缩为概要注入请求，兼顾上下文连贯与成本控制。

7.5 拟真主动聊天

通过链式定时器与持久化到期时刻实现低后台占用的主动消息调度，配合后台通知模拟真人互动，并提供完整门禁与日志可观测机制。

7.6 丰富的辅助能力

内置自定义表情包、语音朗读、多会话、API 预设、调试日志面板、聊天记录导出等功能，形成完整、易用的端侧聊天工具链。

8 测试结果

8.1 测试环境

测试在开发机（Windows 10）以 Node.js 运行自动化断言脚本，并在 Android 真机、微信开发者工具、H5 浏览器进行手工冒烟测试。

8.2 测试内容与结论

针对核心逻辑编写断言测试：记忆系统（三级存储、时间衰减、去重合并、召回冷却、分层检索、维护升降级、Memory 行解析）与表情包系统（名称校验、增删改、解析拆分、占位提取、拖拽重排）均通过全部断言。

对聊天发送、回复格式校验、情景更新、记忆入库、上下文压缩、拟真调度、语音合成等主流链路进行手工验证，功能符合设计预期，回复格式校验与记忆写入保持稳定。

跨端验证显示：App、H5、微信小程序三端核心功能一致，存储与运行正常，符合设计要求。

9 使用说明

9.1 安装与导入

开发者使用 HBuilderX 导入本项目工程，在开发环境配置大模型接口后，将工程运行到浏览器、真机或模拟器；也可按平台打包发布。用户在设置页填写接口地址、API Key 与模型名并保存，即可开始对话。

9.2 功能使用

聊天：在输入框输入消息发送；点击头部人格名可配置当前对话人格；历史弹窗可切换、删除会话或压缩上文、导出对话；聊天记录超过设定条数时出现侧边滑块定位消息，并支持一键回到底部与加载更早消息。

记忆管理：记忆页可查看、新建、编辑记忆内容、优先级与级别，支持筛选与多选删除；记忆由 AI 自动维护，也支持手动管理。

表情包：表情管理页可批量上传并逐张命名、改名、删除与拖拽排序；聊天中点击表情栏可插入 \$ 表情名 \$ 占位。

拟真聊天：在设置中开启拟真聊天并设定活动时段与频率，AI 会主动发消息；支持后台通知与调试发送。

语音阅读：在设置页开启语音阅读并填写语音接口 Key，AI 回复将以语音朗读，表情不朗读。

设置与调试：设置页集中管理接口、思考模式、数据与背景等；调试日志面板可查看请求、响应与错误详情，便于排查问题。

10 界面与交互说明

10.1 聊天主界面

聊天页顶部展示 AI 伙伴名称（点击可配置人格）、历史、新对话与清空按钮。中部为消息列表，支持滚动、侧边滑块定位、一键回到底部，以及上翻加载更早消息；背景图片支持自定义设置。底部为输入栏，右侧可展开表情栏插入表情，支持唤起键盘。情景条随对话动态展示 AI 判断的用户当前情景，点击可编辑或清除。

10.2 记忆管理界面

记忆页以列表展示全部记忆，支持按关键字筛选、新建记忆、编辑内容与优先级级别、开启多选模式批量删除，帮助用户直观掌控 AI 的个性化记忆。

10.3 表情管理界面

表情管理页支持批量上传图片并逐张命名，可改名、删除，支持长按拖动排序，实时同步到聊天表情栏。

10.4 设置界面

设置页以分区形式组织：接口配置、思考模式、请求次数、人格配置、聊天表情包、语音阅读、聊天背景、上下文压缩、拟真聊天、数据管理与调试日志等区块，并提供若干设置子页（外观、接口、人格、拟真、语音、压缩、数据、日志、帮助、关于）。

10.5 交互反馈

界面统一使用主色 #5b7cfa 与 rpx 自适应单位，弹窗共用统一的遮罩与面板样式；列表数据复制副本渲染避免污染存储；消息列表渲染采用窗口化与稳定标识键，保障表情较多场景下的流畅体验。

11 异常处理与容错

11.1 接口容错

LLM 请求失败或返回格式异常时，软件依据格式校验结果自动重新请求，最多重试设置项指定的次数，达上限抛出错误并由页面提示；服务端不识别思考模式参数返回错误时自动移除该参数降级重试。回复校验不通过时不写入历史，避免脏数据进入聊天与记忆。语音首次播放失败会重新合成一次以获得新音频链接重试，兜住瞬时网络或解码问题。

11.2 存储容错

所有持久化写入均带异常兜底，避免写入失败抛出影响界面；存储层对平台差异（App 与小程序存文件、H5 存 base64）做出适配与降级，兼容旧数据结构并自动迁移。

11.3 调度容错

拟真聊天调度使用链式定时器与持久化到期时刻，进程重启后自动对齐；每次到期无论发送成败均记录日志（成功、跳过附原因、异常附堆栈），杜绝静默失败。

11.4 数据安全

聊天记录、记忆与设置全部保存在用户本地设备，不上传云端；导出对话记录与调试日志均不包含接口密钥等敏感信息。

12 版本记录

- **V1.0.0 (初始版)**：完成聊天主链路、人格预设、三级记忆雏形、多会话、设置与数据持久化；
- **V1.1.x**：新增上下文压缩、情景感知、表情包系统与聊天背景图；
- **V1.2.x**：新增语音阅读（TTS）、上下文压缩优化、接口预设与思考模式控制；
- **V1.3.x**：新增拟真聊天与后台通知、回复格式严格校验、调试日志面板；
- **V1.4.x**：优化记忆系统（MMR 检索、容量管理）、消息列表渲染性能、导出与数据管理。

当前登记版本为 V1.4.3。各版本兼容演进，持续完善功能与稳定性。

13 附录：主要程序文件说明

13.1 聊天服务层

chat.js：聊天门面与发送主链路；chat-state.js：共享状态；chat-settings.js：设置域；chat-conversations.js：会话域；chat-compress.js：压缩域；chat-proactive.js：拟真聊天域。

13.2 存储层

storage.js：持久化门面；storage-state.js：存储底层与共享状态；storage-conversations.js：会话域；storage-scene.js：情景域；storage-api.js：API 预设域；storage-background.js：背景图域。

13.3 记忆与提示词

memory.js: 记忆核心; memory-similarity.js: 相似度; memory-parse.js: Memory 行解析; memory-constants.js: 常量; prompts.js: 系统提示词与人格预设。

13.4 辅助能力

emojis.js: 表情数据层; llm.js: LLM 客户端; tts.js: 语音阅读; log.js: 调试日志; notify.js: 系统通知; export.js: 记录导出。

13.5 页面层

pages/chat/chat.vue 及 components 目录: 聊天页与七个子组件; pages/memory/memory.vue: 记忆页; pages/emoji/emoji.vue: 表情页; pages/settings 目录: 设置页与各设置子页。

13.6 测试脚本

scripts/test-memory.mjs: 记忆核心逻辑断言测试, 覆盖三级存储、时间衰减、去重合并、召回冷却、分层检索与维护升降级等场景; scripts/test-emojis.mjs: 表情包逻辑断言测试, 覆盖名称校验、增删改、解析拆分、占位提取与重排等场景。两个脚本均在 Node 环境通过 npm test 运行, 对核心纯函数逻辑进行自动化回归验证。

13.7 工程配置与入口文件

pages.json: 页面注册、窗口样式与 tabBar 配置; manifest.json: 应用标识、版本号、平台发布信息与权限声明; App.vue: 应用入口, 负责启动初始化、存储迁移与前后台状态同步; main.js: 框架入口, 创建应用实例并挂载。

14 结语

ChabotAI 伙伴 V1.4.3 以“无后端、纯端侧、跨平台”为核心设计理念, 围绕大语言模型构建了集智能对话、三级记忆、情景感知、上下文压缩、表情包互动、语音阅读与拟真主动聊天于一体的完整端侧聊天应用。软件在架构上采用门面与域模块分层设计, 在工程上以自动化断言测试保障核心逻辑质量, 在体验上兼顾多端一致性与平台特性, 形成了良好的可扩展性与可维护性。本文档与随附源程序共同构成软件的完整技术资料, 供登记审查与后续版本演进参考。

软件名称: ChabotAI 伙伴

软件版本: V1.4.3

著作权人: 陈聪

文档类型: 软件设计说明书

编制日期: 2026 年 9 月